

图论与网络 — 第二次作业解答

说明：数值与图表由仓库内 Python 脚本自动生成，数据集来自 SNAP。

1 网络社团结构概述

网络社团结构（community structure）是指复杂网络在拓扑上呈现出的一类中层组织形态：同一社团内部的节点之间连接相对稠密，而社团之间的连接相对稀疏。该现象最早在社交网络、生物网络与互联网拓扑中被大量观测到，刻画了系统在功能、社交或语义层面的分组特征。

社团划分（community detection）的核心思想是在不显式给定标签的前提下，利用拓扑结构把节点划分为若干群组。常见做法包括：基于最优化的模块度最大化、基于统计推断的随机块模型、基于传播的模块划分、以及近年来基于深度表征学习的端到端社团发现。

评价准则方面，最常用的是模块度（modularity） Q ：给定划分 $\{C_i\}$ （将节点划分为若干社团）， Q 度量相对于随机基准图的社团内连接盈余；其中 m 为边数， k_i 为节点 i 的度， $\delta(c_i, c_j)$ 表示节点 i, j 是否属于同一社团（Kronecker δ ）。 Q 越大通常表示社团内部相对更稠密、社团之间更稀疏，但模块度也存在分辨率限制等问题。此外还可结合归一化互信息（NMI）、conductance、切割平衡度，以及面向重叠社团的评测指标。

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j)$$

常见社团挖掘算法（简要）

- 传统（非深度学习）：
 - (1) GN（边介数迭代删除）——思想清晰、可解释性强，但复杂度高，适合中小规模；
 - (2) 模块度贪心（Fast greedy）——近似最大化模块度；
 - (3) Louvain / Leiden——多层级模块度优化，速度与质量兼顾，工业界常用；
 - (4) Infomap——最小描述长度与随机游走信息流；
 - (5) 标签传播（LPA）——线性时间，适合超大规模但结果不稳定；
 - (6) 随机块模型推断（SBM/MMSB）——生成式统计建模。
- 深度学习 / 表征学习：
 - (1) 图自编码器（GAE/VGAE）——编码拓扑并用重构或变分目标学习节点向量再聚类；
 - (2) DMoN 等可微模块度最大化网络——直接对模块度代理做梯度优化；
 - (3) GraphWave、Graph2Vec 等结构性表征；
 - (4) 随机游走 + Skip-gram（DeepWalk/node2vec）——通过神经网络嵌入捕获邻近结构，再接聚类完成社团划分。

2 经典社团算法：Louvain

本节选取 Louvain (Blondel 等) 算法。其核心思想是通过局部贪心移动节点所属社团，使模块度单调不减；先在单层图上迭代合并节点至相邻社团，再将社团收缩成超节点构建上层网络，反复直至模块度增益收敛。算法复杂度近似线性于边数，适合大规模稀疏网络。

实验数据集：Zachary Karate Club (34 节点，78 边)。下图给出社团划分与可视化结果。




图 2-1 Karate Club — Louvain 社团着色

数值结果：社团数 4，模块度 $Q \approx 0.4449$ ，运行时间约 0.0014 s。

2.1 （拓展）DeepWalk + KMeans 表征社团

作为深度学习/表征学习路线的代表，本文采用 DeepWalk：通过随机游走生成节点序列，再用 Skip-gram（神经网络语言模型）学习低维嵌入；嵌入向量经 KMeans 聚类得到社团划分。该方法利用浅层神经网络捕获高阶邻近性，适合作为与传统模块度方法的对比基线。

Karate — DeepWalk+KMeans (k=4), Q=0.3578




图 2-2 DeepWalk+KMeans 社团可视化 (Karate)

模块度对比: Louvain $Q \approx 0.4439$; DeepWalk+KMeans $Q \approx 0.3578$ 。DeepWalk 运行耗时包含游走采样与词向量训练, 通常高于 Louvain; 其对噪声与随机种子更敏感, 鲁棒性一般弱于显式模块度优化。

3 无向网络节点重要性: 经典拓扑指标

给定无向简单图 $G = (V, E)$, 记 $|V| = n$, 邻接矩阵为 $A = (A_{ij})$ 。以下给出四类常用拓扑指标的公式 (常用标准化版本)。

3.1 公式推导 (摘要)

- 度中心性 (degree centrality): 刻画局部连接的广度, 计算最简单。

$$C_D(v) = \frac{\deg(v)}{n-1}$$

- 介数中心性 (betweenness centrality) : σ_{st} 为 s-t 最短路径条数, $\sigma_{st}(v)$ 为其中经过 v 的条数; 该指标刻画节点作为“桥梁”的程度。大规模网络可用 Brandes 算法近似线性时间求解。

$$C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

- 接近中心性 (closeness centrality) : $d(v, u)$ 为最短路径长度; 若网络不连通, 可采用调和版本或仅在最大连通子图上定义。

$$C_C(v) = \frac{n-1}{\sum_{u \neq v} d(v, u)}$$

- 特征向量中心性 (eigenvector centrality) : 设邻接矩阵为 A, 取最大特征值 $\lambda_{\max}$ 及对应非负主特征向量 x ; 节点重要性与其分量 x_v 成正比, 体现“重要邻居带来递归加权”。

$$Ax = \lambda_{\max}x, \quad x \geq 0$$

3.2 小规模示例计算

示例网络边集: $[[0, 1], [0, 2], [1, 2], [1, 3], [2, 3], [3, 4], [4, 5], [4, 6], [5, 6]]$

节点	degree	betweenness	closeness	eigenvector	rank_degree	rank_betweenness	rank_closeness	rank_eigenvector
0	0.333333	0.0	0.4	0.362003	5	5	7	4
1	0.5	0.133333	0.545455	0.490383	1	3	3	2
2	0.5	0.133333	0.545455	0.490383	1	3	3	1
3	0.5	0.6	0.666667	0.476196	1	1	1	3
4	0.5	0.533333	0.6	0.30938	1	2	2	5

		3		1				
5	0.3333 33	0.0	0.4285 71	0.18100 2	5	5	5	6
6	0.3333 33	0.0	0.4285 71	0.18100 2	5	5	5	6

规律分析：高度节点往往在度与特征向量中心性上占优；割点或桥接位置的节点介数更高；接近中心性更偏好处于地理（拓扑）中心的节点；不同指标排名可能出现分歧，反映“重要性”维度不同。

4 PageRank 算法

PageRank 将网页浏览建模为带传送（teleport）的随机游走：以概率 α 沿出链随机跳转，以概率 $(1-\alpha)$ 均匀传送至任一节点。稳态分布即为重要性评分；其中 N 为节点数， $L_{out}(v)$ 表示 v 的（加权）出度之和。对有向加权网络，可按边权对转移概率做归一化。

$$PR^{(t+1)}(u) = \frac{1-\alpha}{N} + \alpha \sum_{v \rightarrow u} \frac{PR^{(t)}(v)}{L_{out}(v)}$$




图 4-1 PageRank 与加权入度的相关性散点图

数据集: SNAP soc-sign-bitcoinotc (directed, weighted trust ratings); 节点 5881, 边 35592。PageRank 运行约 0.024 s。PageRank 与加权入度的皮尔逊相关系数约为 0.9316。总体上高度被指向且来自高分上游的节点 PageRank 更高, 但与单纯入度并不完全一致 (反映了上游权重与全局递归效应)。

排名前十节点示例: 35(1.43e-02), 2642(1.14e-02), 7(7.80e-03), 2028(7.67e-03), 1810(7.18e-03), 1(6.74e-03), 4172(5.62e-03), 905(5.41e-03), 1953(5.27e-03), 3744(4.83e-03)

5 (拓展) 深度学习类节点影响力: DeepWalk 嵌入范数

这里选取基于随机游走 + Skip-gram 的结构嵌入 (DeepWalk) 作为“神经网络表征学习”代表作。模型结构: 随机游走序列 $\rightarrow$ Word2Vec (浅层神经网络) $\rightarrow$ 得到节点向量 z_v 。影响力评分可采用欧氏范数 (嵌入能量); 直觉上在多语境游走中频繁共现的节点往往获得更大的范数。该方法与 PageRank 均为全局结构信息的聚合, 但优化目标不同: 前者最大化局部上下文预测似然, 后者求解随机游走的稳态分布。

$$\|z_v\|_2 = \sqrt{\sum_k z_{v,k}^2}$$

在 Bitcoin OTC 网络的弱连通巨片子图 (约 900 节点) 上, 嵌入影响力与 PageRank 的 Spearman 相关约为 0.1534; 与度中心性约为 -0.0045; 与 (无向化) 介数约为 0.0872。整体上嵌入范数与 PageRank、度相关为正, 但不完全等价; 介数强调最短路径桥梁, 嵌入更偏向共现统计。

6 大规模网络挖掘: Email-Eu-core

数据集来自 SNAP: 欧洲研究机构电子邮件网络 (有向)。下文在无向化后的巨连通分量上报告社团与影响力结果。

(1) 基本统计: 节点数 1005, 边数 25571, 网络密度 (有向) ≈ 0.025342 ; 无向平均度 ≈ 33.2458 ; 最大连通分量节点数 986; 平均聚类系数 ≈ 0.4071 ; 平均最短路径长度 ≈ 2.5869 。




图 6-1 度分布直方图

(2) 社团挖掘: Louvain 模块度 ≈ 0.4291 (社团数 8) ; DeepWalk+KMeans 模块度 ≈ 0.4125 (社团数 8) 。Louvain 直接优化模块度目标, 通常更可解释; 嵌入聚类能捕捉非线性结构但模块度不一定最优。物理意义上, 社团对应邮件往来密切的研究小组或协作圈子。



图 6-2 DeepWalk 社团着色的网络布局（抽样可视化）

(3) 影响力：度中心性与 PageRank 的 Spearman 相关 ≈ 0.8962 ；嵌入范数与 PageRank ≈ 0.2322 。核心节点（PageRank Top）：1, 130, 160, 62, 86, 107, 365, 121, 5, 129, 183, 64；嵌入范数 Top：414, 605, 846, 645, 479, 697, 907, 927, 335, 43, 957, 9。这些节点多为跨组桥梁或高频通讯个体，对信息扩散至关重要。

附录：代码与复现

具体代码可访问 <https://github.com/Kevin-Liang-0211/net>

文件夹「作业 2」内包含 requirements.txt、run_all.p、equation_images.py 与 src/*.py。运行：python3 run_all.py 生成 results_summary.json 与 figures/。正文中的公式均由 matplotlib 数学排版渲染为高清插图插入 Word；